

HW4

xw-zeng

2022-10-20

(1)

Derive the Maximum likelihood estimation function.

$$\begin{aligned}l(\beta) &= \sum_{i=1}^N \{y_i \log p(x_i; \beta) + (1 - y_i) \log (1 - p(x_i; \beta))\} \\&= \sum_i \{y_i x_i^\top \beta - \log (1 + \exp (x_i^\top \beta))\} \\&= y^\top X \beta - b^\top \mathbf{1} \\b &= (b(x_1), b(x_2), \dots, b(x_N))^\top \quad \text{and} \quad b(x_i) = \log (1 + \exp (x_i^\top \beta)) \\l'(\beta) &= \frac{\partial l(\beta)}{\partial \beta^\top} = X^\top y - \frac{\partial b^\top}{\partial \beta^\top} \mathbf{1} \\\frac{\partial b^\top}{\partial \beta^\top} &= \frac{\partial}{\partial \beta^\top} (\log (1 + \exp (x_1^\top \beta)), \dots, \log (1 + \exp (x_N^\top \beta))) \\&= \left(\frac{x_1 \cdot \exp (x_1^\top \beta)}{1 + \exp (x_1^\top \beta)}, \dots, \frac{x_N \cdot \exp (x_N^\top \beta)}{1 + \exp (x_N^\top \beta)} \right) \\l'(\beta) &= X^\top y - X^\top p \\p &= (p(x_1; \beta), \dots, p(x_N; \beta))^\top \quad \text{and} \quad p(x_i; \beta) = \frac{\exp (x_i^\top \beta)}{1 + \exp (x_i^\top \beta)}\end{aligned}$$

(2)

Define the log likelihood function.

```
logL <- function(beta){
  b <- function(x, beta){
    out <- c()
    for (i in 1:nrow(x)){out <- c(out, log(1 + exp(x[i, ] %*% beta)))}
    return (out)
  }
  t(y) %*% X %*% beta - sum(b(X, beta))
}
```

Define the first derivative of log likelihood function.

```
logL_1 <- function(beta){
  p <- function(x, beta){
    out <- c()
    for (i in 1:nrow(x)){out <- c(out, 1 / (1 + exp(-1 * x[i, ] %*% beta)))}
    return (out)
  }
  t(X) %*% (y - p(X, beta))
}
```

Compute the second derivative of log likelihood function.

$$\begin{aligned}
 l''(\beta) &= \frac{\partial l'(\beta)}{\partial \beta^\top} = -X^\top \frac{\partial p}{\partial \beta^\top} \\
 \frac{\partial p}{\partial \beta^\top} &= \frac{\partial}{\partial \beta^\top} \left(1 - \frac{1}{1 + \exp(x_1^\top \beta)}, \dots, 1 - \frac{1}{1 + \exp(x_N^\top \beta)} \right)^\top \\
 &= \left(\frac{x_1 \exp(x_1^\top \beta)}{(1 + \exp(x_1^\top \beta))^2}, \dots, \frac{x_N \exp(x_N^\top \beta)}{(1 + \exp(x_N^\top \beta))^2} \right)^\top \\
 l''(\beta) &= -X^\top \text{diag} \left(\frac{\exp(x_i^\top \beta)}{(1 + \exp(x_i^\top \beta))^2} \right) X = -X^\top W X
 \end{aligned}$$

Define the second derivative of log likelihood function.

```
logL_2 <- function(beta){
  w <- function(x, beta){
    out <- matrix(0, nrow(x), nrow(x))
    for (i in 1:nrow(x)){
      out[i, i] <- exp(x[i, ] %*% beta) / (1 + exp(x[i, ] %*% beta)) ^ 2
    }
  }
}
```

```

    }
    return (out)
  }
  - t(X) %*% w(X, beta) %*% X
}

```

Define the **Newton-Raphson method** function.

- **start**: starting value of beta.
- **criterion**: absolute convergence criterion, by default set as $1e^{-5}$.

```

Newton_Raphson <- function(start, criterion = 1e-5){
  ##Initial values
  x <- start
  ##Updating function
  delta <- function(x){solve(logL_2(x)) %*% logL_1(x)}
  ##Main
  while (max(abs(delta(x))) >= criterion){x <- x - delta(x)}
  ##Output
  structure(list(N = nrow(X),
                best_beta = x,
                epsilon = x - beta,
                best_logL = logL(x),
                start = start))
}

```

Compute results with $N = 200, 500, 800, 1000$.

```

##True beta
beta <- c(0.5, 1.2, -1)
df <- matrix(NA, 1, 4)
##Set a random seed to obtain repeatable results
set.seed(2022)
##N = 200, 500, 800, 1000
for (N in c(200, 500, 800, 1000)){
  ##Simulate for 200 rounds
  for (i in 1:200){
    ##Generate values of X
    X <- matrix(1, N, 3)
    for (j in 2:3){X[, j] <- rnorm(N)}
    ##Generate values of y
    p <- exp(X %*% beta) / (1 + exp(X %*% beta))
  }
}

```

```

y <- c()
for (j in 1:N){y <- c(y, rbinom(1, 1, p[j]))}
##Track the difference between beta hat and true beta
df <- rbind(na.omit(df), cbind(N, t(Newton_Raphson(c(0,0,0))$epsilon)))}}
##Transform the df matrix to a data frame
df <- data.frame(df)
df$N <- as.factor(df$N)

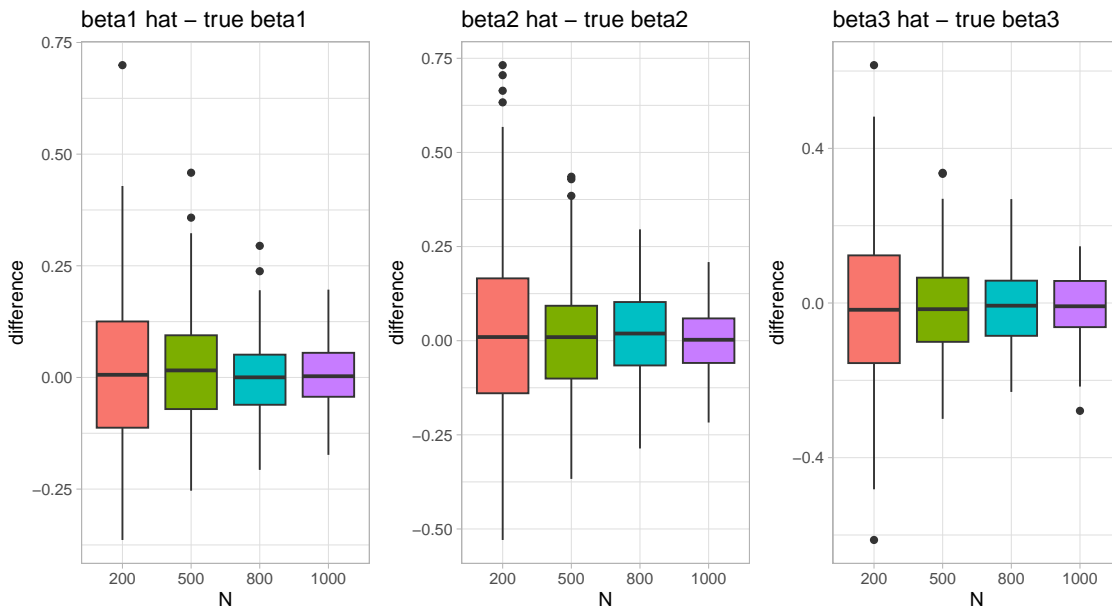
```

For each j , draw $(\hat{\beta}_j^{(r)} - \beta_j)$ in boxplot for $N = 200, 500, 800, 1000$.

```

p1 = ggplot(df, mapping = aes(x = N, y = V2, fill = N)) +
  geom_boxplot() + guides(fill = 'none') + theme_light() +
  labs(title = 'beta1 hat - true beta1', y = 'difference')
p2 = ggplot(df, mapping = aes(x = N, y = V3, fill = N)) +
  geom_boxplot() + guides(fill = 'none') + theme_light() +
  labs(title = 'beta2 hat - true beta2', y = 'difference')
p3 = ggplot(df, mapping = aes(x = N, y = V4, fill = N)) +
  geom_boxplot() + guides(fill = 'none') + theme_light() +
  labs(title = 'beta3 hat - true beta3', y = 'difference')
p1 + p2 + p3

```



从箱线图中我们可以看出，基本上随着样本量的增加， $(\hat{\beta}_j^{(r)} - \beta_j)$ 不断向 0 靠近，且方差也在不断减小。这说明增大样本量能够一定程度上减少对真实 β 的估计误差。

(3)

考虑一种简单的情况，当数据中不存在 $f(x^+) = f(x^-)$ 时，“排序”损失的定义如下：

$$\ell_{rank} = \frac{1}{m^+m^-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} (I(f(x^+) < f(x^-)))$$

Proof 1

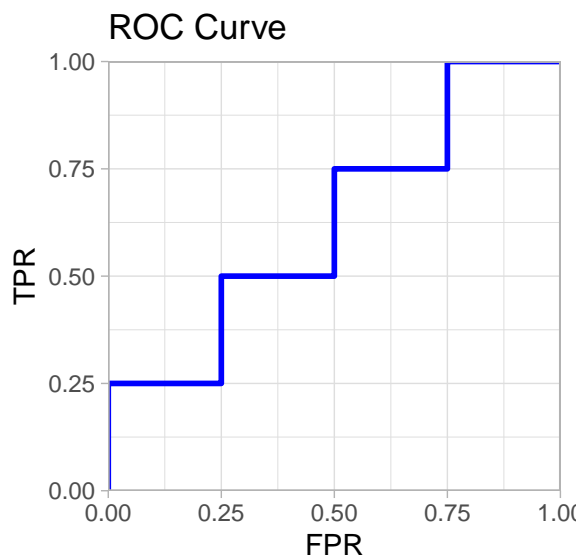
要证明 $AUC = 1 - \ell_{rank}$ 即为有限样本 ROC 曲线下方的面积，等价于证明 ℓ_{rank} 表示有限样本 ROC 曲线与 y 轴围成的面积。

首先生成一幅 ROC 曲线图作为例子。

```
fpr <- c(0, 0, 1/4, 1/4, 2/4, 2/4, 3/4, 3/4, 1)
tpr <- c(0, 1/4, 1/4, 2/4, 2/4, 3/4, 3/4, 1, 1)
p <- ggplot(mapping = aes(x = fpr, y = tpr)) + theme_light() +
  geom_path(size = 1, color = 'blue') +
  scale_x_continuous(expand = c(0, 0)) +
  scale_y_continuous(expand = c(0, 0)) +
  labs(title = 'ROC Curve', x = 'FPR', y = 'TPR')
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
```

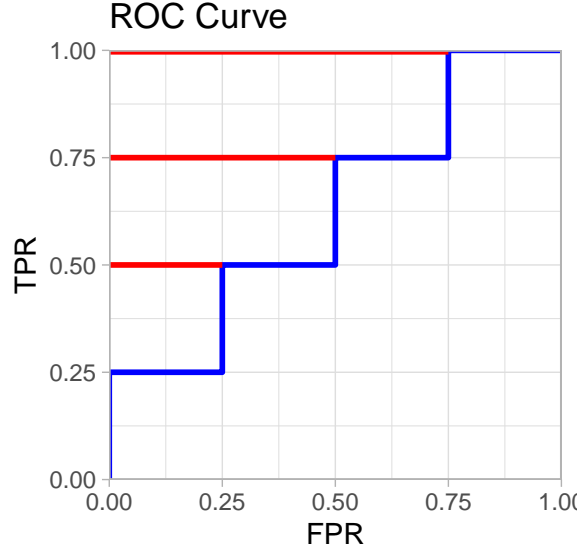
p



我们要求 ROC 与 y 轴围成的面积可以用矩形的面积公式长 \times 宽进行计算（因为我们假设数据中不存在 $f(x^+) = f(x^-)$ 的情况，就不会出现梯形）。

我们首先把 ROC 曲线上的多边形水平切分为几个矩形（垂直切也可以，原理都是一样的），如下图所示。

```
p + geom_line(aes(x = c(0, 1/4), y = c(2/4, 2/4)), color = 'red', size = 1) +
  geom_line(aes(x = c(0, 2/4), y = c(3/4, 3/4)), color = 'red', size = 1) +
  geom_line(aes(x = c(0, 3/4), y = c(1, 1)), color = 'red', size = 1.5)
```



水平的线段表示在分类阈值变动的过程中只新增了假正例，垂直的线段表示只新增了真正例。每新增一个假正例，x 的坐标就新增一个步长 $\frac{1}{m^-}$ ；每新增一个真正例，y 的坐标就新增一个步长 $\frac{1}{m^+}$ 。

因此，每一个矩形的宽都为 $\frac{1}{m^-}$ ，每一个矩形的长就表示在当前有多少个负例满足 $f(m^-)$ 大于分类阈值，即 $\sum_{x^- \in D^-} \frac{1}{m^-} (I(f(x^+) < f(x^-)))$ 。

故每个矩形的面积 $S = \frac{1}{m^+} \sum_{x^- \in D^-} \frac{1}{m^-} (I(f(x^+) < f(x^-)))$ ，最后遍历所有真正例对所有矩形求和 $\sum_{x^+ \in D^+} S$ ，就能够得到 ROC 曲线与 y 轴围成的面积。

我们现在再回顾一下 ℓ_{rank} 的公式，发现该公式就等于我们推导出来的 ROC 曲线与 y 轴围成的面积，而 y 轴与 x 轴围成的正方形面积为 1，故 $1 - \ell_{rank}$ 就是有限样本 ROC 曲线下方的面积，得证。

$$\begin{aligned} \ell_{rank} &= \frac{1}{m^+ m^-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} (I(f(x^+) < f(x^-))) \\ &= \sum_{x^+ \in D^+} \frac{1}{m^+} \sum_{x^- \in D^-} \frac{1}{m^-} (I(f(x^+) < f(x^-))) \end{aligned}$$

Proof 2

现在我们换一种理解方式。ROC 曲线下的面积表示的其实是从数据集中随机抽取正负例对 $\{x^+, x^-\}$ ，模型 $f(x)$ 对正例的打分 $f(x^+)$ 大于对负例的打分 $f(x^-)$ 的概率，即正样本排序

在负样本之前的概率。先前我们定义了 $AUC = 1 - \ell_{rank}$ ，因此问题转化为证明 ℓ_{rank} 为正样本排序在负样本之后的概率，即排序错误的概率（我们假设数据中不存在 $f(x^+) = f(x^-)$ 的情况，因此正负样本的得分都不同）。

排序错误的正负例对的组合共有：

$$\sum_{x^+ \in D^+} \sum_{x^- \in D^-} (I(f(x^+) < f(x^-)))$$

正负例对的组合共有 m^+m^- 个，故排序错误的概率为：

$$\frac{\sum_{x^+ \in D^+} \sum_{x^- \in D^-} (I(f(x^+) < f(x^-)))}{m^+m^-}$$

该式就等于 ℓ_{rank} ，问题得证。

$$\begin{aligned} \ell_{rank} &= \frac{1}{m^+m^-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} (I(f(x^+) < f(x^-))) \\ &= \frac{\sum_{x^+ \in D^+} \sum_{x^- \in D^-} (I(f(x^+) < f(x^-)))}{m^+m^-} \end{aligned}$$

THE END. THANKS! ^_^