

HW8

xw-zeng

2022-11-28

## 理论推导

### 1. 对偶问题

软间隔最大化问题的原问题为：

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \xi_i^2 \\ \text{s.t.} \quad & y_i (w \cdot x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

写出拉格朗日函数：

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i \{y_i (w \cdot x_i + b) - 1 + \xi_i\} - \sum_{i=1}^N \mu_i \xi_i$$

其中  $\alpha_i \geq 0, \mu_i \geq 0$ ，转化为极大极小问题，首先求解极小问题，关于  $w, b, \xi$  求偏导：

$$\nabla_w L(w, b, \xi, \alpha, \mu) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

$$\nabla_b L(w, b, \xi, \alpha, \mu) = - \sum_{i=1}^N \alpha_i y_i = 0$$

$$\nabla_{\xi_i} L(w, b, \xi, \alpha, \mu) = C - \alpha_i - \mu_i = 0$$

化简后可得：

$$w = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$C = \alpha_i + \mu_i$$

代入拉格朗日函数：

$$\begin{aligned} & \frac{1}{2}\|w\|^2 + C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \alpha_i (1 - \xi_i - y_i (w^T x_i + b)) - \sum_{i=1}^N \mu_i \xi_i \\ &= \frac{1}{2}\|w\|^2 + \sum_{i=1}^N \alpha_i (1 - y_i (w^T x_i + b)) + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i \xi_i - \sum_{i=1}^N \mu_i \xi_i \\ &= -\frac{1}{2} \sum_{i=1}^N \alpha_i y_i x_i^T \sum_{i=1}^N \alpha_i y_i x_i + \sum_{i=1}^N \alpha_i + \sum_{i=1}^N C \xi_i - \sum_{i=1}^N \alpha_i \xi_i - \sum_{i=1}^N \mu_i \xi_i \\ &= -\frac{1}{2} \sum_{i=1}^N \alpha_i y_i x_i^T \sum_{i=1}^N \alpha_i y_i x_i + \sum_{i=1}^N \alpha_i + \sum_{i=1}^N (C - \alpha_i - \mu_i) \xi_i \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j \\ &= \min_{w,b,\xi} L(w, b, \alpha, \xi, \mu) \end{aligned}$$

再求解极大问题，即为对偶问题：

$$\begin{aligned}\max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \alpha, \xi, \mu) &= \max_{\alpha, \mu} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j \\ &= \max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j\end{aligned}$$

约束条件为：

$$\begin{aligned}\alpha_i &\geq 0 \\ \mu_i &\geq 0 \\ C &= \alpha_i + \mu_i \\ \Rightarrow 0 &\leq \alpha_i \leq C, 0 \leq \mu_i \leq C\end{aligned}$$

## 2. 核方法

首先看两个例子：

1. 对  $p = 2, n = 2$ ，有  $\phi_2(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$ ，使得：

$$\begin{aligned}K(x, z) &= (x^T z)^2 = \left( (x_1, x_2)^T (z_1, z_2) \right)^2 \\ &= (x_1 z_1 + x_2 z_2)^2 \\ &= x_1^2 z_1^2 + 2x_1 z_1 x_2 z_2 + x_2^2 z_2^2 \\ &= (x_1^2, \sqrt{2}x_1x_2, x_2^2)^T (z_1^2, \sqrt{2}z_1z_2, z_2^2)^T \\ &:= \phi_2(x) \cdot \phi_2(z)\end{aligned}$$

2. 对  $p = 3, n = 2$ ，有  $\phi_3(x) = (x_1^3, \sqrt{3}x_1^2x_2, \sqrt{3}x_1x_2^2, x_2^3)$ ，使得：

$$\begin{aligned}K(x, z) &= (x^T z)^3 = \left( (x_1, x_2)^T (z_1, z_2) \right)^3 \\ &= (x_1 z_1 + x_2 z_2)^3 \\ &= x_1^3 z_1^3 + 3x_1^2 z_1^2 x_2 z_2 + 3x_1 z_1 x_2^2 z_2^2 + x_2^3 z_2^3 \\ &= (x_1^3, \sqrt{3}x_1^2x_2, \sqrt{3}x_1x_2^2, x_2^3)^T (z_1^3, \sqrt{3}z_1^2z_2, \sqrt{3}z_1z_2^2, z_2^3) \\ &:= \phi_3(x) \cdot \phi_3(z)\end{aligned}$$

因此，我们猜测对于任意  $p, n$ ，都能为  $K(x, z)$  找到从  $\mathcal{X}$  到希尔伯特空间  $\mathcal{H}$  的映射  $\phi$ ，使得：

$$K(x, z) = \phi(x) \cdot \phi(z)$$

令  $x, z \in \mathcal{R}^n$ ，使用数学归纳法进行证明：

当  $p = 1$  时，有  $\phi_1(x) = x$  使得：

$$K(x, z) = \phi_1(x) \cdot \phi_1(z) = x \cdot z$$

假设  $p = k$  时, 存在  $\phi_k$  使得:

$$K(x, z) = \phi_k(x) \cdot \phi_k(z)$$

则  $p = k + 1$  时:

$$K(x, z) = (x \cdot z)^{k+1} = (x \cdot z)^k (x \cdot z) = (\phi_k(x) \cdot \phi_k(z)) (x \cdot z)$$

不妨假设  $\phi_k$  由以下形式变换得到:

$$\phi_k(x) = (f_1(x), f_2(x), \dots, f_m(x))^T$$

则有:

$$\begin{aligned} K(x, z) &= (f_1(x)f_1(z) + f_2(x)f_2(z) + \dots + f_m(x)f_m(z)) (x_1z_1 + x_2z_2 + \dots + x_nz_n) \\ &= f_1(x)f_1(z) (x_1z_1 + x_2z_2 + \dots + x_nz_n) + f_2(x)f_2(z) (x_1z_1 + x_2z_2 + \dots + x_nz_n) + \dots \\ &\quad + f_m(x)f_m(z) (x_1z_1 + x_2z_2 + \dots + x_nz_n) \\ &= (f_1(x)x_1) (f_1(z)z_1) + (f_1(x)x_2) (f_1(z)z_2) + \dots + (f_1(x)x_n) (f_1(z)z_n) + (f_2(x)x_1) (f_2(z)z_1) + \dots \\ &\quad + (f_2(x)x_n) (f_2(z)z_n) + (f_m(x)x_1) (f_m(z)z_1) + \dots + (f_m(x)x_n) (f_m(z)z_n) \\ &:= \phi_{k+1}(x) \cdot \phi_{k+1}(z) \end{aligned}$$

故有  $\phi_{k+1}(x) = (f_1(x)x_1, \dots, f_1(x)x_n, f_2(x)x_1, \dots, f_2(x)x_n, \dots, f_m(x)x_1, \dots, f_m(x)x_n)^T$  使得  $K(x, z) = (x \cdot z)^{k+1} = \phi_{k+1}(x) \cdot \phi_{k+1}(z)$ , 结论在  $p = k + 1$  时也成立, 得证。

对任意  $x_i \in \mathcal{X} (i = 1, \dots, n)$ , 构造  $K(x, z)$  关于  $x_1, x_2, \dots, x_n$  的 Gram 矩阵:

$$K = [K_{ij}]_{n \times n} = [K(x_i, x_j)]_{n \times n}$$

则对任意  $a_1, a_2, \dots, a_n \in \mathcal{R}$ , 有:

$$\begin{aligned} \sum_{i,j=1}^n a_i a_j K(x_i, x_j) &= \sum_{i,j=1}^n a_i a_j (\phi(x_i) \cdot \phi(x_j)) \\ &= \left( \sum_i a_i \phi(x_i) \right) \cdot \left( \sum_j a_j \phi(x_j) \right) \\ &= \left\| \sum_i a_i \phi(x_i) \right\|^2 \geq 0 \end{aligned}$$

因此,  $K(x, z)$  关于  $x_1, x_2, \dots, x_n$  的 Gram 矩阵为半正定矩阵。

内积的正整数幂函数满足对称性 (因为内积本身就具有对称性):

$$K(x, z) = (x \cdot z)^p = (z \cdot x)^p$$

综上所述, 内积的正整数幂函数  $K(x, z) = (x, z)^p$  满足正定核的充要条件, 是正定核函数, 问题得证。

## 征信系列-用户行为数据分析

载入 R 包。

```
library(ggplot2) # plot beautiful graphs
library(rpart) # decision tree
library(e1071) # svm
library(pROC) # draw ROC curve
library(patchwork) # merge two ggplots
```

定义画 ROC 曲线的函数。

```
show_roc <- function(true, pred, train_or_test){
  roc_curve <- roc(true, pred)
  plot(roc_curve, print.auc = TRUE, auc.polygon = TRUE, legacy.axes = TRUE,
       grid = c(0.1, 0.2), grid.col = c('green', 'red'), max.auc.polygon = TRUE,
       auc.polygon.col = 'skyblue', print.thres = TRUE, main = paste0('ROC Curve on ',
       ifelse(train_or_test == 'train', 'Training', 'Test'), ' Data'))
}
```

定义画混淆矩阵 (confusion matrix) 的函数。

```
show_cm <- function(df, modelname){
  df$pred <- df[, 2]
  out <- ggplot(df, aes(pred, true_class, fill = Freq)) +
    geom_tile() + geom_text(aes(label = Freq)) +
    scale_fill_gradient(low = 'white', high = '#3575b5') +
    labs(x = 'Pred', y = 'True', title = paste('Confusion Matrix of', modelname),
         fill = '是否违约') + guides(fill = 'none') + theme_light()
  return (out)
}
```

## 分析任务 1

读入数据。

```
data <- read.csv('simudata.csv')
```

将变量 `black` (是否违约) 转化为因子型变量。

```
data$black <- factor(data$black, levels = c(0, 1), labels = c('未违约', '违约'))
```

## 分析任务 2

按照 7:3 的比例划分训练集和测试集。

```
set.seed(1234)
idx_train <- sample(1:nrow(data), 0.7 * nrow(data))
data_train <- data[idx_train, ]
data_test <- data[-idx_train, ]
```

用决策树模型在训练集上进行建模。

```
fit_rpart <- rpart(black ~ ., data_train)
```

用 SVM 模型在训练集上进行建模。

```
fit_svm <- svm(black ~ ., data_train, probability = TRUE)
```

使用建立好的模型对测试集进行预测，输出预测概率，便于绘制 ROC 曲线。


```
pred_rpart_prob <- predict(fit_rpart, data_test, type = 'prob')
pred_svm_prob <- attr(predict(fit_svm, data_test, probability = TRUE), 'probabilities')
```

再输出预测类型，便于绘制混淆矩阵。

```
pred_rpart_class <- predict(fit_rpart, data_test, type = 'class')
pred_svm_class <- predict(fit_svm, data_test)
```

分别画出决策树模型、SVM 模型在测试集上的 ROC 曲线。

```
par(mfrow=c(1,2))
show_roc(data_test$black, pred_rpart_prob[, 1], 'test')
show_roc(data_test$black, pred_svm_prob[, 1], 'test')
```



由上图，决策树的 AUC 大小为 0.668，SVM 的 AUC 大小为 0.817，这说明 SVM 模型在该问题上的分类能力远高于决策树。

分别计算两个模型的分类准确率 accuracy。

```
true_class <- data_test$black
pred_rpart <- table(true_class, pred_rpart_class)
pred_svm <- table(true_class, pred_svm_class)
acc_rpart <- sum(diag(pred_rpart)) / nrow(data_test)
acc_svm <- sum(diag(pred_svm)) / nrow(data_test)
print(paste0('决策树的准确率为: ', round(acc_rpart * 100, 2), '%'))
```

```
## [1] "决策树的准确率为: 71.04%"
```

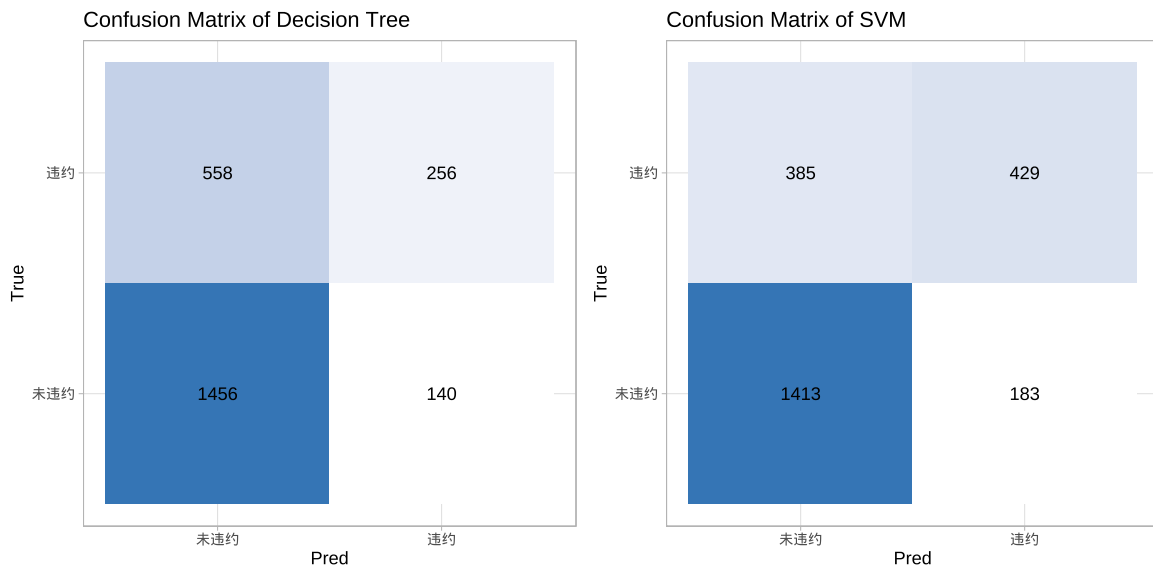
```
print(paste0('SVM 的准确率为: ', round(acc_svm * 100, 2), '%'))
```

```
## [1] "SVM的准确率为: 76.43%"
```

故 SVM 分类准确率比决策树的准确率更高，效果更好。

最后分别画出决策树模型、SVM 模型在测试集上的混淆矩阵。

```
p1 <- show_cm(data.frame(pred_rpart), 'Decision Tree')
p2 <- show_cm(data.frame(pred_svm), 'SVM')
p1 + p2
```



由上图可知，SVM 在预测的真正例比决策树更多，即更有能力分辨出违约用户；而两个模型对负例的预测效果相差不大。

综上所述，SVM 模型的效果比决策树模型好。

**THE END. THANKS! ^\_\_^**